


# Segmentação

Flávio Araújo

# Segmentação

- Subdivide a imagem em partes ou objetos que a compõem:
  - O nível até o qual essa subdivisão deve ser realizada depende do problema sendo resolvido;
  - Segmentação finaliza quando objetos de interesse ao problema são detectados.
- A segmentação é uma das tarefas mais difíceis em visão computacional. Se ela falha, a maioria dos processos subsequentes estará comprometido.
  - Embora o ser humano possa facilmente identificar regiões com as mesmas características ou objetos em uma imagem, em um computador essa tarefa pode ser complexa.

# Segmentação




**FIGURE 10.1** (a) Image containing a region of constant intensity. (b) Image showing the boundary of the inner region, obtained from intensity discontinuities. (c) Result of segmenting the image into two regions. (d) Image containing a textured region. (e) Result of edge computations. Note the large number of small edges that are connected to the original boundary, making it difficult to find a unique boundary using only edge information. (f) Result of segmentation based on region properties.

# Segmentação

- O processo de identificação dos pixels pertencentes a um mesmo objeto ou região é chamado de segmentação;
- As principais técnicas de segmentação de imagens podem ser classificadas nas seguintes categorias:
  - Limiarização;
  - Detecção de descontinuidades;
  - Crescimento de região;
  - QuadTree;
  - Contorno ativo;
  - Agrupamento;
  - Redes Neurais Convolucionais.

# Limiarização

- Consiste em separar regiões de uma imagem quando esta apresenta duas classes:
  - Fundo e objeto (background, foreground)
- Características:
  - Propriedades intuitivas;
  - Simplicidade de implementação;
  - Desempenho computacional.



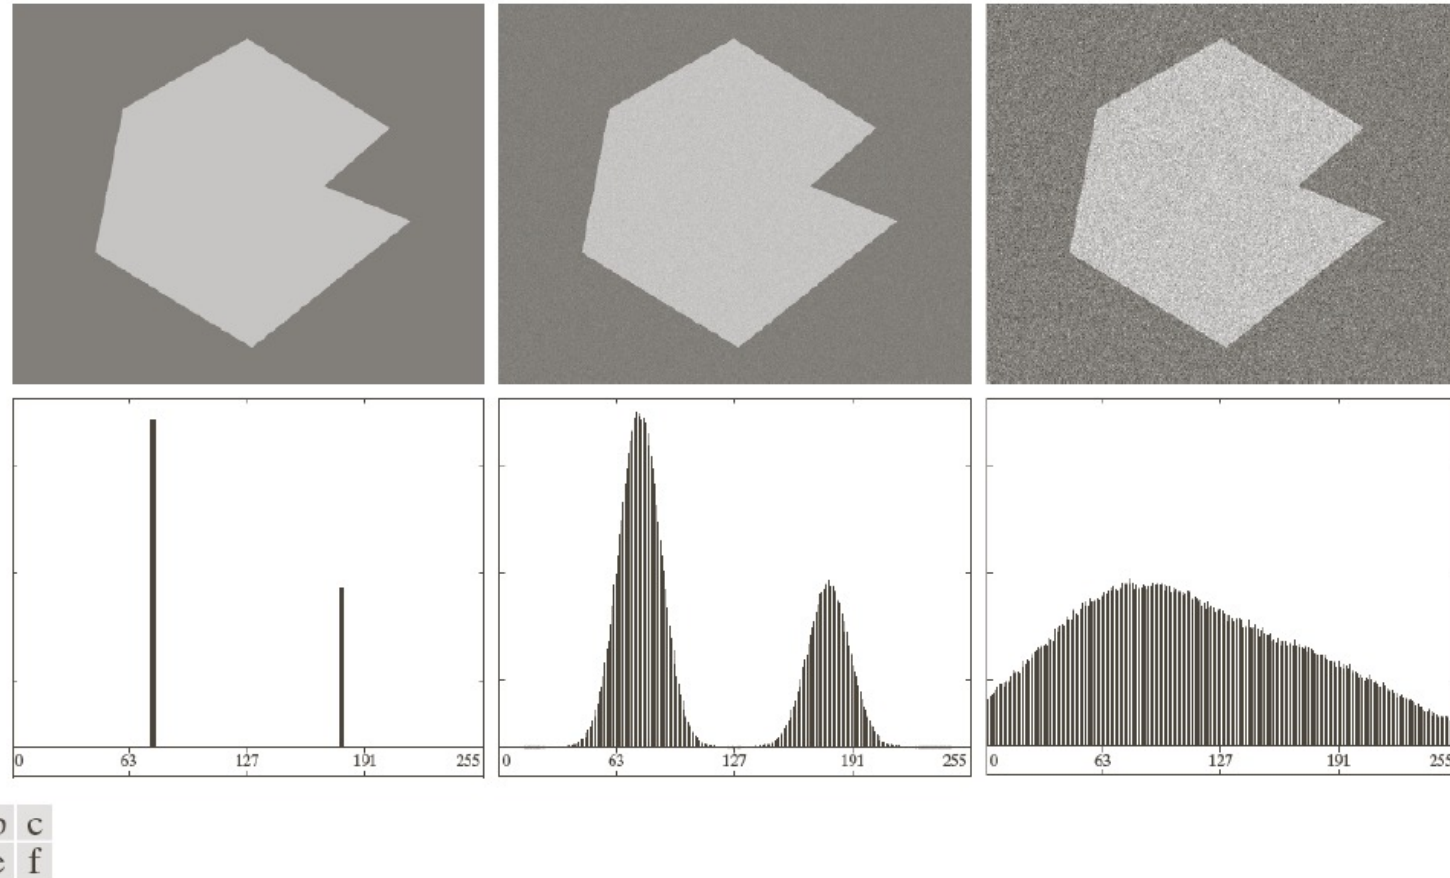
# Limiarização

- A maneira óbvia de extrair objetos é selecionar um limiar  $T$  que separe os dois grupos;
- Então, para cada ponto  $(x,y)$  tal que  $f(x,y) > T$  é denominado ponto do objeto, caso contrario, fundo;

$$g(x,y) = \begin{cases} 1 & \text{se } f(x,y) > T \\ 0 & \text{se } f(x,y) \leq T \end{cases}$$

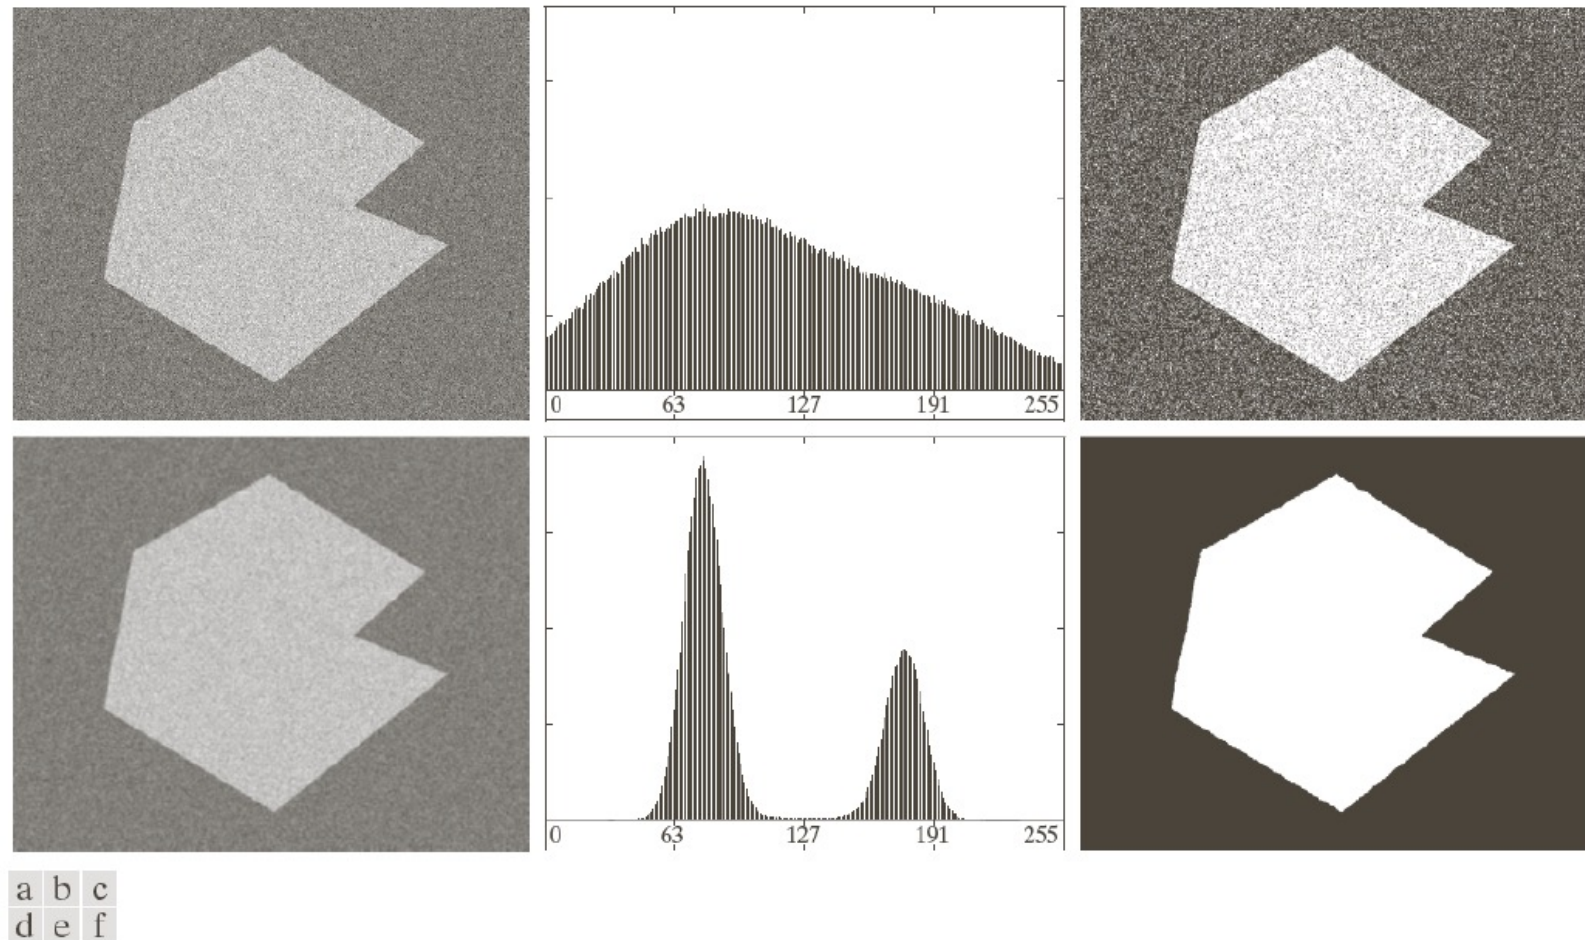
- Nesse caso,  $T$  depende apenas de  $f(x,y)$  e portanto é conhecida como limiarização global.

# Limiarização



**FIGURE 10.36** (a) Noiseless 8-bit image. (b) Image with additive Gaussian noise of mean 0 and standard deviation of 10 intensity levels. (c) Image with additive Gaussian noise of mean 0 and standard deviation of 50 intensity levels. (d)–(f) Corresponding histograms.

# Limiarização




**FIGURE 10.40** (a) Noisy image from Fig. 10.36 and (b) its histogram. (c) Result obtained using Otsu's method. (d) Noisy image smoothed using a  $5 \times 5$  averaging mask and (e) its histogram. (f) Result of thresholding using Otsu's method.



# Limiarização Adaptativa

- Resultados satisfatórios são obtidos com a limiarização global. Porém em alguns casos, mais de um limiar deve ser utilizado.
- A limiarização adaptativa seleciona um limiar individual para cada pixel baseado na intensidade estimada em sua vizinhança local.
- Isso permite uma melhor limiarização quando não existem cumes bem definidos.



# Limiarização Adaptativa

- Mecanismo para limiarização adaptativa:
  - A imagem original é dividida em sub-imagens;
  - Um limiar é determinado independentemente para cada região;
  - Cada sub-imagem é então processada usando um limiar local;
  - A nova imagem é formada pela concatenação das sub-imagens.

# Detecção de descontinuidades


- Levam em consideração o fato de que entre duas regiões deve existir uma fronteira;
- Procura-se identificar descontinuidades que possam representar as bordas da região;
- A operação clássica: **gradiente**
  - Intensifica variações de tonalidade resultando em uma imagem com pixels mais intensos;
  - Para a identificação das bordas pode ser aplicado um processo de limiarização nos valores absolutos da imagem de gradiente.
- Problema na aplicação do gradiente:
  - Obtenção de regiões com bordas abertas devido a ruídos ou uso de iluminação não uniforme no processo de aquisição da imagem

# Gradiente de uma imagem

**FIGURE 10.2** (a) Image. (b) Horizontal intensity profile through the center of the image, including the isolated noise point. (c) Simplified profile (the points are joined by dashes for clarity). The image strip corresponds to the intensity profile, and the numbers in the boxes are the intensity values of the dots shown in the profile. The derivatives were obtained using Eqs. (10.2-1) and (10.2-2).

O gradiente de uma imagem é obtida por meio da derivada da imagem:


$$\frac{\delta f}{\delta x} = f'(x) = f(x + 1) - f(x).$$



# Filtro Laplaciano

Máscara do filtro Laplaciano

1	1	1
1	-8	1
1	1	1



a b  
c d

**FIGURE 10.5**

(a) Original image.  
(b) Laplacian image; the magnified section shows the positive/negative double-line effect characteristic of the Laplacian.

(c) Absolute value of the Laplacian.  
(d) Positive values of the Laplacian.

# Máscaras de detecção de linhas

-1	-1	-1	2	-1	-1	-1	2	-1	-1	-1	2
2	2	2	-1	2	-1	-1	2	-1	-1	2	-1
-1	-1	-1	-1	-1	2	-1	2	-1	2	-1	-1
Horizontal			+45°			Vertical			-45°		

**FIGURE 10.6** Line detection masks. Angles are with respect to the axis system in Fig. 2.18(b).

a b  
c d  
e f

**FIGURE 10.7**

(a) Image of a wire-bond template.


(b) Result of processing with the +45° line detector mask in Fig. 10.6.

(c) Zoomed view of the top left region of (b).

(d) Zoomed view of the bottom right region of (b).

(e) The image in (b) with all negative values set to zero.

(f) All points (in white) whose values satisfied the condition  $g \geq T$ , where  $g$  is the image in (e). (The points in (f) were enlarged to make them easier to see.)



# Sobel e Prewitt

Detectar linhas horizontais e verticais

-1	-1	-1	-1	0	1
0	0	0	-1	0	1
1	1	1	-1	0	1

Prewitt

-1	-2	-1	-1	0	1
0	0	0	-2	0	2
1	2	1	-1	0	1

Sobel

0	1	1	-1	-1	0
-1	0	1	-1	0	1
-1	-1	0	0	1	1

Prewitt

0	1	2	-2	-1	0
-1	0	1	-1	0	1
-2	-1	0	0	1	2


Sobel

a	b
c	d

**FIGURE 10.15**  
Prewitt and Sobel  
masks for  
detecting diagonal  
edges.



# Sobel e Prewitt




a	b
c	d

**FIGURE 10.16**

(a) Original image of size  $834 \times 1114$  pixels, with intensity values scaled to the range  $[0, 1]$ .  
(b)  $|g_x|$ , the component of the gradient in the  $x$ -direction, obtained using the Sobel mask in Fig. 10.14(f) to filter the image.  
(c)  $|g_y|$ , obtained using the mask in Fig. 10.14(g).  
(d) The gradient image,  $|g_x| + |g_y|$ .



# Sobel e Prewitt



a	b
c	d

**FIGURE 10.18**

Same sequence as in Fig. 10.16, but with the original image smoothed using a  $5 \times 5$  averaging filter prior to edge detection.

# Crescimento de regiões

- Agrupa pixels ou sub-regiões em regiões maiores;
- Começa com um conjunto de pontos, chamados sementes, e a partir deles, cresce as regiões anexando a cada ponto semente aqueles pixels que possuam propriedades similares:
  - Nível de cinza, textura, cor.
- Propriedade P: Diferença absoluta entre os níveis de cinza daqueles entre o pixel e semente deve ser menor que T;
- Desvantagens:
  - Seleção das sementes e propriedade P.


Sementes

0	0	5	6	7
1	1	5	8	7
0	1	6	7	7
2	0	7	6	6
0	1	5	6	5

T=3

0	0	5	6	7
1	1	5	8	7
0	1	6	7	7
2	0	7	6	6
0	1	5	6	5

# Crescimento de regiões






# QuadTree

- Uma abordagem para segmentação consiste em subdividir a imagem sucessivamente em quadrantes cada vez menores caso ele seja formado por mais de uma região;
- Em seguida os quadrantes com propriedades semelhantes são fundidos;

a b

**FIGURE 10.42**

(a) Partitioned image.  
(b) Corresponding quadtree.



# Contorno ativo

- Os contornos ativos utilizam curvas definidas sobre o domínio da imagem que podem mover-se, controladas por ação de **forças internas (intrínsecas à geometria da curva)** e **externas (derivadas da imagem)**, em busca de uma posição de equilíbrio, ou seja, a localização do contorno da estrutura de interesse;
- Existem dois tipos principais de modelos de contornos ativos: paramétricos, como as ***snakes***, e modelos geométricos, como o ***Level Set*** e o ***Fast Marching***.
- Os modelos geométricos definem curvas que se movimentam de acordo com uma função velocidade. Essa função pode depender de diversas grandezas físicas que, por sua vez, dependem de características extraídas da imagem e de restrições geométricas da própria função. Uma vantagem dessa abordagem é que o conjunto inicial não deve necessariamente ser uma única curva, mas um conjunto de curvas independentes que podem se fundir para adaptar-se à topologia local.

# Snakes




- Nesse modelo, a curva possui uma posição inicial e uma função objetiva associada, denominada função de energia. O objetivo é minimizar essa função:

$$\mathbf{v}(s) = (x(s), y(s)) \quad E = \int_0^1 \frac{1}{2} (\alpha |v'(s)|^2 + \beta |v''(s)|^2) + E_{ext}(v(s)) ds$$

- O primeiro termo é a energia interna,  $\alpha$  controla o quanto o contorno pode ser esticado ou contraído, enquanto  $\beta$  controla a elasticidade, ou seja, o quanto o contorno pode ser entortado para gerar cantos;
- Desvantagens:
  - O contorno inicial, deve ser similar e estar relativamente próximo da fronteira real para garantir a convergência correta, caso contrario, ruídos presentes no interior do objeto atrairão a *snake* para seus mínimos locais, gerando, assim, falsas bordas.
  - A incapacidade de lidar com mudanças topológicas, limitando a segmentação de objetos de múltiplos contornos, com buracos ou ramificações.



# Snakes



# Modelos Geométricos





- Esses modelos definem uma curva que se move de acordo com uma função de velocidade a fim de rastrear a evolução da superfície:

$$F = F(L, G, I)$$

- L corresponde as propriedades locais (direção normal e curvatura), G as propriedades globais dependentes da posição e forma da curva e I representa o gradiente de tons de cinza;
- No *Level Set* as superfícies podem expandir ou se contrair em função do valor de velocidade. Já no *Fast Marching* a superfície sempre se propaga para fora ou para dentro.
- As principais vantagens desses modelos são a capacidade de gerar cantos e lidar com mudanças topológicas.



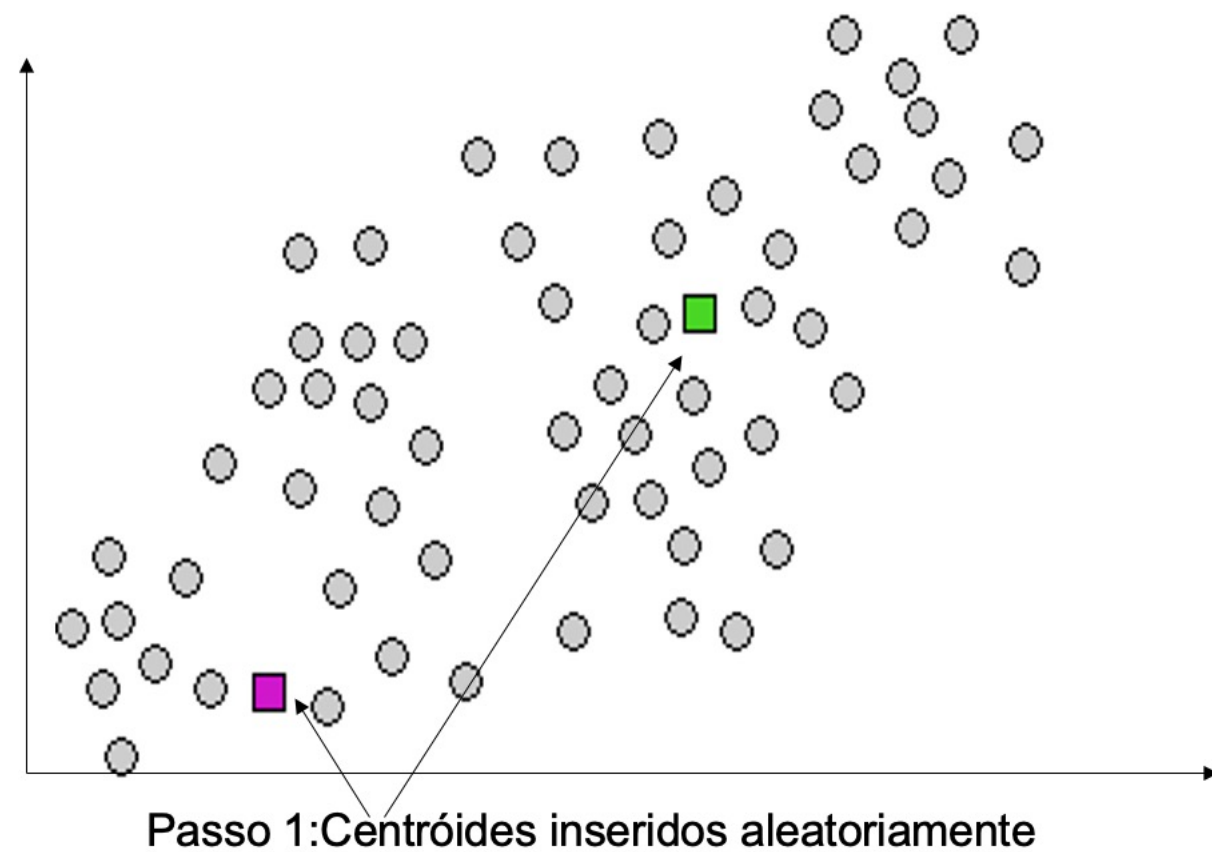
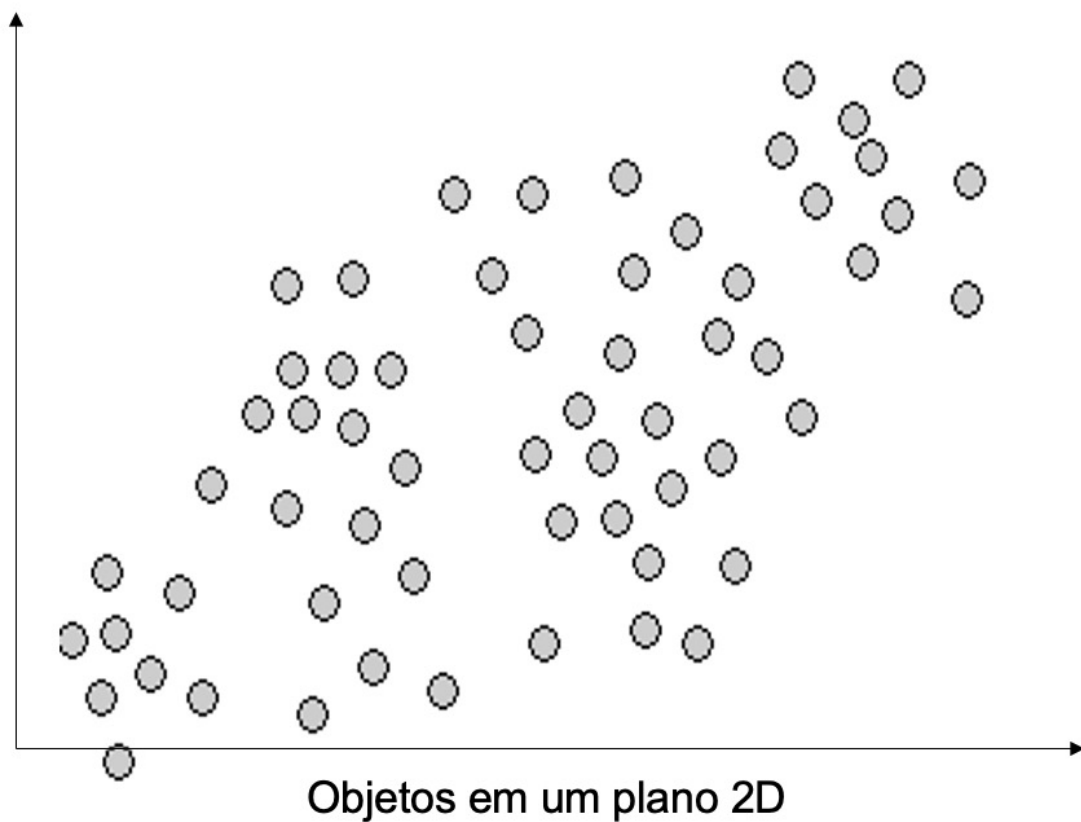
# Modelos Geométricos




# Agrupamento

- Realiza o agrupamento de pixels por similaridade;
- O K-means é a técnica mais simples de aprendizagem não supervisionada.
  - 1 - Fixa  $k$  centroides (de maneira aleatória), um para cada grupo (clusters);
  - 2 - Associa cada indivíduo ao seu centroide mais próximo;
  - 3 - Recalcular os centroides com base nos indivíduos classificados;
  - 4 - Repete os passos 2 e 3 até que os centroides não sejam modificados.
- Características:
  - Possibilidade de trabalhar com grandes bases de dados;
  - Baixo custo computacional
  - **Classe**: representada por um centro (ponto);
  - Número de classes iniciais pode impor estrutura errônea.


# K-means



# K-means



Passo 2: Atribuir a cada objeto o centróide mais próximo



Passo 3: Recalcular os centróides

# K-means

